

Predição de Gravidade de Acidentes em Rodovias Federais Brasileiras:

Uma Análise Preditiva com Enriquecimento por Dados Climáticos

Tópicos em Engenharia de Software — Ciência de Dados

João Ricardo Prado Siqueira¹

¹Departamento de Computação – DACOM
Universidade Tecnológica Federal do Paraná – UTFPR-CM
Campo Mourão – PR – Brasil

joaosiqueira.2004@alunos.utfpr.edu.br

Resumo. Este trabalho propõe um estudo empírico sobre a predição de gravidade de acidentes em rodovias federais brasileiras utilizando os dados abertos da Polícia Rodoviária Federal (PRF), cobrindo o período de 2023 a 2025, com aproximadamente de 63 a 75 mil registros por ano agrupados por ocorrência. O objetivo é identificar os fatores mais associados à gravidade dos acidentes e comparar abordagens preditivas — Regressão Logística, Random Forest e XGBoost — com e sem enriquecimento por dados climáticos históricos da API Open-Meteo. O *venue-alvo* é o **KDMiLe** (trilha de artigo completo) ou, alternativamente, o **WTAG**, com ênfase em mineração de dados e aprendizado de máquina aplicados.

1. Identificação do Grupo e Repositório

O trabalho é desenvolvido individualmente por mim, João Ricardo Prado Siqueira. O repositório Git do projeto, com commits documentados, está disponível em: <https://github.com/J0aoSiqueira/predicao-gravidade-acidentes>

2. Venue-Alvo e Tipo de Contribuição

O *venue-alvo* principal é o **KDMiLe** (*Symposium on Knowledge Discovery, Mining and Learning*). Caso o escopo final se mostre mais enxuto, a alternativa é o **WTAG** (*Workshop de Trabalhos de Alunos de Graduação*) das conferências KDMiLe/SBBD. O tipo de contribuição é um **estudo empírico/aplicado**, em que é utilizado os dados reais para responder perguntas de pesquisa por meio de comparação de abordagens preditivas.

3. Dataset Principal e Contexto

O dataset principal provém dos **Dados Abertos da Polícia Rodoviária Federal (PRF)** [Polícia Rodoviária Federal 2024], publicados mensalmente em formato CSV e disponíveis em <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos>. Serão utilizadas as bases de 2020 a 2025, agrupadas por ocorrência, totalizando aproximadamente 337 a 350 mil registros antes da limpeza.

Cada registro representa um envolvido em um acidente de trânsito em rodovias federais e contém variáveis como: rodovia (br) e quilômetro (km); município e UF;

data, hora e dia da semana; condição meteorológica, tipo de pista e traçado da via; tipo e marca do veículo; tipo de envolvimento (condutor, passageiro, pedestre); sexo e idade do envolvido; causa e tipo do acidente; e **estado físico** da vítima (variável-alvo: ileso, ferido leve, ferido grave ou morto).

4. Enriquecimento com Fontes Externas

Para responder à segunda pergunta de pesquisa, o dataset será enriquecido com duas fontes externas:

- **Open-Meteo API** [Open-Meteo 2024] (<https://open-meteo.com>): API gratuita e sem necessidade de cadastro que fornece dados meteorológicos históricos por coordenada geográfica e data. Serão recuperadas variáveis de precipitação acumulada, temperatura e cobertura de nuvens para cada acidente, com base nas colunas de latitude, longitude e data/hora já presentes no dataset da PRF.
- **Frota municipal — SENATRAN/dados.gov.br**: total de veículos registrados por município, permitindo calcular uma taxa de acidentalidade relativa (acidentes por veículo) e enriquecer o contexto do local de cada ocorrência.

A integração será realizada via SQL (DuckDB) e Python (Pandas), com justificativa documentada para cada coluna adicionada, tratamento de ausências provenientes das fontes externas e avaliação do impacto do enriquecimento sobre o desempenho preditivo.

5. Perguntas de Pesquisa e Hipóteses

Perguntas de pesquisa:

1. Quais fatores (horário, condição da via, tipo de veículo, causa do acidente) são mais preditivos da gravidade do acidente em rodovias federais brasileiras?
2. O enriquecimento com dados climáticos históricos melhora a capacidade preditiva dos modelos em relação ao dataset original?

Hipóteses testáveis:

- H1** Acidentes noturnos e em condições de pista molhada apresentam probabilidade significativamente maior de resultar em vítimas fatais ou feridos graves.
- H2** Motociclistas têm distribuição de gravidade de desfecho substancialmente diferente (mais grave) em comparação com ocupantes de automóveis.
- H3** Modelos baseados em árvores de decisão (Random Forest, XGBoost) superam a Regressão Logística na tarefa de classificação multiclasse de gravidade.

6. Trabalhos Relacionados (Lista Inicial)

A predição de gravidade de acidentes de trânsito é amplamente estudada na literatura. [Islam et al. 2023] avaliaram modelos de aprendizado de máquina — incluindo Regressão Logística, Random Forest e Redes Neurais Artificiais — sobre dez anos de dados de acidentes do Reino Unido ($N = 2.047.256$), obtendo acurácia de 87% com Random Forest e identificando a idade e o tipo de veículo como variáveis de maior importância preditiva. [Hoque et al. 2022] demonstraram a superioridade do XGBoost sobre KNN, Regressão Logística e Naive Bayes na predição de gravidade de acidentes únicos e

múltiplos, com AUC-ROC de 0,88 para acidentes de veículo único. [Barua et al. 2014] investigaram correlação espacial entre acidentes de diferentes gravidades, reforçando a importância de variáveis de localização e condições de via. No contexto nacional, [Carnauba et al. 2024] realizaram análise exploratória sobre o dataset da PRF (2019–2023), identificando padrões temporais relevantes — maior concentração de acidentes aos finais de semana e após as 17h — mas sem modelagem preditiva. A principal diferença deste estudo é a combinação de dados recentes da PRF (2023–2025), enriquecimento climático via API [Open-Meteo 2024], pipeline reproduzível com DuckDB e comparação controlada de abordagens preditivas.

Referências

- Barua, S., El-Basyouny, K., and Islam, M. T. (2014). A full Bayesian multivariate count data model of collision severity with spatial correlation. *Analytic Methods in Accident Research*, 3:28–43.
- Carnauba, L., Medeiros, M., Camilo, E., Cardoso, J., and Medeiros, F. (2024). Uso de Business Intelligence para mensuração de acidentes rodoviários através da base de dados da Polícia Rodoviária Federal. In *Anais do XXXIX Simpósio Brasileiro de Banco de Dados (SBBD 2024)*, pages 65–70, Florianópolis, SC, Brasil. SBC.
- Hoque, M. S., Hwang, C. L., and Kim, Y. J. (2022). Hybrid feature selection-based machine learning classification system for the prediction of injury severity in single and multiple-vehicle accidents. *PLOS ONE*, 17(2):e0262941.
- Islam, S. M., Al-Amin, M., Tran, T. N., Abdalla, T., and Rahman, S. (2023). Evaluating the effectiveness of machine learning techniques in forecasting the severity of traffic accidents. *Heliyon*, 9(8):e18812.
- Open-Meteo (2024). Open-meteo historical weather API. API pública. Disponível em: <https://open-meteo.com>. Acesso em: maio 2025.
- Polícia Rodoviária Federal (2024). Dados abertos da PRF: Sistema BAT — boletim de acidente de trânsito. Portal de Dados Abertos. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>. Acesso em: maio 2025.