

Predição de Gravidade de Acidentes em Rodovias Federais Brasileiras: Uma Comparação de Abordagens Preditivas com Enriquecimento por Dados Climáticos

João Ricardo Prado Siqueira¹

¹Departamento de Computação – DACOM
Universidade Tecnológica Federal do Paraná – UTFPR-CM
Campo Mourão – PR – Brasil

joaosiqueira.2004@alunos.utfpr.edu.br

Resumo. *[TODO: Escrever após os resultados finais. Deve conter: problema, dataset (PRF 2020–2025, ~400 mil ocorrências), metodologia (3 modelos comparados), principal resultado numérico e conclusão em até 150 palavras.]*

Abstract. *[TODO: Versão em inglês do resumo, mesma estrutura.]*

1. Introdução

Os acidentes de trânsito constituem um grave problema de saúde pública no Brasil. Segundo o Anuário Estatístico da Polícia Rodoviária Federal [Polícia Rodoviária Federal 2024], **[TODO: inserir número]** ocorrências foram registradas nas rodovias federais em 2024, resultando em **[TODO: inserir]** mortes e **[TODO: inserir]** feridos graves.

A predição automática da gravidade de um acidente a partir de características contextuais (horário, condição meteorológica, tipo de via, causa) pode subsidiar políticas públicas de prevenção e priorização de recursos emergenciais. Embora a literatura internacional apresente estudos robustos sobre o tema [Islam et al. 2023, Hoque et al. 2022], trabalhos com dados exclusivamente brasileiros e com avaliação controlada do efeito de enriquecimento por dados externos permanecem escassos [Carnauba et al. 2024].

Contribuição deste trabalho. Realizamos um estudo empírico com os dados abertos da PRF (2020–2025, ~**[TODO: N]** ocorrências agrupadas por ocorrência), comparando três abordagens preditivas — Regressão Logística (baseline), *Random Forest* e *XGBoost* — com e sem enriquecimento por dados climáticos históricos provenientes da API Open-Meteo [Open-Meteo 2024]. Investigamos também os fatores com maior poder preditivo sobre a gravidade dos acidentes.

Perguntas de pesquisa:

- PR1** Quais fatores são mais preditivos da gravidade de acidentes em rodovias federais brasileiras?
- PR2** O enriquecimento com dados climáticos históricos melhora a capacidade preditiva dos modelos em relação ao dataset original?

O restante do artigo está organizado como segue: a Seção 2 revisa os trabalhos relacionados; a Seção 3 descreve o dataset e o processo de curadoria; a Seção 4 detalha a metodologia; a Seção 5 apresenta a configuração experimental; a Seção 6 discute os resultados; a Seção 7 aponta ameaças à validade; e a Seção 8 conclui o trabalho.

2. Trabalhos Relacionados

Esta seção revisa os trabalhos mais relevantes em três frentes: (i) aplicação de aprendizado de máquina à predição de gravidade de acidentes; (ii) uso de dados contextuais externos (clima, infraestrutura) como enriquecimento; e (iii) análises sobre o dataset específico da PRF.

2.1. Predição de Gravidade com Aprendizado de Máquina

Islam et al. [Islam et al. 2023] avaliaram Regressão Logística, *Random Forest* e Redes Neurais em 2,04 milhões de acidentes do Reino Unido, obtendo acurácia de 87% com *Random Forest* e identificando a idade do condutor e o tipo de veículo como variáveis de maior importância preditiva. Hoque et al. [Hoque et al. 2022] demonstraram a superioridade do XGBoost sobre KNN, Regressão Logística e Naive Bayes na predição de gravidade, com AUC-ROC de 0,88 para acidentes de veículo único. Chen et al. [?] aplicaram SVM em acidentes de capotamento e destacaram a relevância de variáveis de traçado da via. Barua et al. [Barua et al. 2014] investigaram correlação espacial entre acidentes, reforçando a importância de variáveis de localização.

2.2. Enriquecimento com Dados Externos

[TODO: Revisar literatura sobre uso de dados climáticos/meteorológicos em modelos de acidentes. Incluir 2–3 referências sobre precipitação e visibilidade como preditores.]

2.3. Análises sobre Dados da PRF

Carnauba et al. [Carnauba et al. 2024] realizaram análise descritiva exploratória com dados da PRF (2019–2023) usando ferramentas de BI, identificando padrões temporais (maior concentração após as 17h e nos finais de semana), mas sem modelagem preditiva.

Posicionamento deste trabalho. Em relação à literatura nacional, diferenciamos pelo foco preditivo e pela avaliação controlada do efeito do enriquecimento climático. Em relação à literatura internacional, contribuimos com um recorte geográfico inédito (rodovias federais brasileiras) e com um período recente (2020–2025).

3. Dados e Definição do Problema

3.1. Fonte de Dados

O dataset principal provém dos **Dados Abertos da Polícia Rodoviária Federal** [Polícia Rodoviária Federal 2024], sistema BAT (*Boletim de Acidente de Trânsito*), arquivos anuais em CSV (separador ‘;’, codificação ISO-8859-1), disponíveis publicamente em formato agrupado por ocorrência. Utilizamos os anos 2020, 2021, 2022, 2023, 2024 e 2025 (parcial), totalizando **[TODO: N]** registros antes da limpeza.

3.2. Variáveis Disponíveis

Cada ocorrência contém **[TODO: N]** variáveis, sumarizadas na Tabela 1.

Tabela 1. Principais variáveis do dataset da PRF (agrupados por ocorrência)

Variável	Tipo	Descrição
data_inversa	Data	Data do acidente
horario	Horário	Hora do acidente (HH:MM:SS)
uf,municipio	Categórica	Localização
br, km	Numérica	Rodovia e quilômetro
causa_acidente	Categórica	Causa principal
tipo_acidente	Categórica	Tipo de colisão/evento
fase_dia	Categórica	Fase do dia (pleno dia, amanhecer, etc.)
condicao_meteorologica	Categórica	Condição do tempo
tipo_pista	Categórica	Simples, dupla, múltipla
tracado_via	Categórica	Reta, curva, cruzamento, etc.
mortos	Numérica	Número de óbitos no local
feridos_leves	Numérica	Número de feridos leves
feridos_graves	Numérica	Número de feridos graves
classificacao_acidente	Categórica	Variável-alvo (ver Seção 3.3)
latitude, longitude	Numérica	Coordenadas geográficas

3.3. Variável-Alvo

A variável-alvo é a `classificacao_acidente`, recodificada em três classes ordinais: 0 = *Sem Vítimas*, 1 = *Com Vítimas Feridas*, 2 = *Com Vítimas Fatais*. A Tabela 2 apresenta a distribuição observada no período estudado.

Tabela 2. Distribuição da variável-alvo (gravidade) — 2020–2025

Classe	Código	Frequência (%)
Sem Vítimas	0	[TODO: XX,X%]
Com Vítimas Feridas	1	[TODO: XX,X%]
Com Vítimas Fatais	2	[TODO: XX,X%]
Total	–	100%

3.4. Enriquecimento com Dados Climáticos

Para responder a PR2, enriquecemos cada ocorrência com três variáveis climáticas recuperadas da API Open-Meteo [Open-Meteo 2024] a partir de `latitude`, `longitude` e `data_hora`: precipitação acumulada na hora do acidente (`precip_mm`), temperatura do ar (`temp_c`) e visibilidade (`visib_km`).

3.5. Limpeza e Preparação

O processo de limpeza envolveu: (i) remoção de duplicatas por `id`; (ii) conversão de coordenadas (vírgula decimal → ponto); (iii) descarte de coordenadas geograficamente inválidas para o território brasileiro; (iv) padronização de strings categóricas para maiúsculas; (v) preenchimento de nulos numéricos pela mediana da coluna. Após limpeza, o dataset resultou em [TODO: N] registros válidos ([TODO: N]% de aproveitamento).

4. Metodologia

4.1. Abordagens Preditivas

Comparamos três classificadores:

- 1. **Regressão Logística (baseline):** modelo linear interpretável, amplamente usado como referência em estudos de gravidade [Islam et al. 2023]. Parâmetros: regularização L2, solver lbfgs, $C = 1$.
- 2. **Random Forest:** ensemble de árvores de decisão com bagging [Hoque et al. 2022]. Permite extrair importância de variáveis. Hiperparâmetros ajustados via validação cruzada: n_estimators, max_depth, min_samples_leaf.
- 3. **XGBoost:** gradient boosting com regularização L1/L2 [Hoque et al. 2022]. Hiperparâmetros: learning_rate, max_depth, subsample, colsample_bytree.

4.2. Engenharia de Features

Além das variáveis originais, criamos as seguintes features derivadas: hora (inteiro 0–23 extraído de horario), mes, ano, noturno (flag binária: 1 se hora ∈ [20, 5]), fim_semana (flag), cond_adversa (flag para chuva, nevoeiro, granizo ou neve).

4.3. Protocolo de Avaliação

Adotamos a divisão estratificada 80%/20% treino/teste (semente 42). A seleção de hiperparâmetros utiliza validação cruzada 5-fold apenas sobre o conjunto de treino. Métricas reportadas no conjunto de teste: **F1-macro**, **AUC-ROC (OvR)**, **acurácia balanceada** e **matriz de confusão** por classe.

Para responder PR2, cada modelo é treinado e avaliado em dois cenários: (A) somente features originais do dataset PRF; (B) features originais + variáveis climáticas da Open-Meteo. A diferença de F1-macro entre (B) e (A) é o estimador do efeito do enriquecimento.

5. Configuração Experimental

5.1. Ambiente

[TODO: Preencher após execução: CPU, RAM, SO, versão Python, versões das bibliotecas (pandas, scikit-learn, xgboost, duckdb).]

5.2. Pipeline Técnico

O pipeline foi implementado em Python 3.11 com as bibliotecas listadas na Tabela 3.

Tabela 3. Principais bibliotecas utilizadas

Biblioteca	Versão	Uso
pandas	[TODO: X.X]	Manipulação de dados
DuckDB	[TODO: X.X]	Consultas SQL analíticas
scikit-learn	[TODO: X.X]	Modelos ML e avaliação
XGBoost	[TODO: X.X]	Gradient boosting
Open-Meteo	API pública	Enriquecimento climático
matplotlib / seaborn	[TODO: X.X]	Visualizações

Todo o código, notebooks e dados processados estão disponíveis no repositório: <https://github.com/joaosiqueira2004/acidentes-prf-ds>

6. Resultados e Discussão

6.1. Análise Exploratória

[TODO: Inserir figuras do notebook: fig1 (evolução anual), fig2 (hora × gravidade), fig3 (top causas), fig4 (gravidade × condição meteorológica), fig5 (gravidade × no-turno), fig6 (UFs), fig7 (série mensal). Discutir os padrões encontrados e relacionar com as hipóteses.]

6.2. Resultados de Classificação — Cenário A (Sem Enriquecimento)

Tabela 4. Desempenho dos modelos sem enriquecimento climático (Cenário A)

Modelo	F1-macro	AUC-ROC	Acurácia Bal.
Regressão Logística	[TODO:]	[TODO:]	[TODO:]
Random Forest	[TODO:]	[TODO:]	[TODO:]
XGBoost	[TODO:]	[TODO:]	[TODO:]

6.3. Resultados de Classificação — Cenário B (Com Enriquecimento)

Tabela 5. Desempenho dos modelos com enriquecimento climático (Cenário B)

Modelo	F1-macro	AUC-ROC	Acurácia Bal.	$\Delta F1$
Regressão Logística	[TODO:]	[TODO:]	[TODO:]	[TODO:]
Random Forest	[TODO:]	[TODO:]	[TODO:]	[TODO:]
XGBoost	[TODO:]	[TODO:]	[TODO:]	[TODO:]

[TODO: Discutir: qual modelo venceu? O enriquecimento ajudou? Qual feature climática foi mais importante? Relacionar com H1, H2, H3.]

6.4. Importância de Variáveis

[TODO: Inserir gráfico de importância de variáveis do Random Forest / XGBoost. Discutir quais features respondem PR1.]

7. Limitações e Ameaças à Validade

Validade interna. A variável-alvo (`classificacao_acidente`) é registrada pelos agentes da PRF no local do acidente; erros de registro e critérios subjetivos de classificação representam ruído não controlado. O enriquecimento climático é realizado com granularidade de ~ 11 km e resolução horária, o que pode não capturar fenômenos localizados como pancadas de chuva.

Validade externa. Os resultados se referem exclusivamente às rodovias federais brasileiras. A generalização para rodovias estaduais ou municipais requer validação adicional.

Validade de construção. A recodificação da variável-alvo em três classes representa uma simplificação; a fronteira entre “ferido leve” e “ferido grave” pode variar conforme o ano e a equipe de registro.

2025 parcial. Os dados de 2025 correspondem apenas aos meses disponíveis no momento da coleta, o que pode introduzir sazonalidade não representada no conjunto de treino.

8. Conclusão

[TODO: Escrever após os resultados. Deve: (a) retomar as perguntas de pesquisa e respondê-las objetivamente com os números obtidos; (b) destacar a principal contribuição; (c) indicar limitações centrais; (d) propor trabalhos futuros (e.g., análise espacial com clustering de trechos críticos, integração com dados de frota do SENATRAN, uso de dados em tempo real para alertas preventivos).]

Referências

- Barua, S., El-Basyouny, K., and Islam, M. T. (2014). A full Bayesian multivariate count data model of collision severity with spatial correlation. *Analytic Methods in Accident Research*, 3:28–43.
- Carnauba, L., Medeiros, M., Camilo, E., Cardoso, J., and Medeiros, F. (2024). Uso de Business Intelligence para mensuração de acidentes rodoviários através da base de dados da Polícia Rodoviária Federal. In *Anais do XXXIX Simpósio Brasileiro de Banco de Dados (SBBDD 2024)*, pages 65–70, Florianópolis, SC, Brasil. SBC.
- Hoque, M. S., Hwang, C. L., and Kim, Y. J. (2022). Hybrid feature selection-based machine learning classification system for the prediction of injury severity in single and multiple-vehicle accidents. *PLOS ONE*, 17(2):e0262941.
- Islam, S. M., Al-Amin, M., Tran, T. N., Abdalla, T., and Rahman, S. (2023). Evaluating the effectiveness of machine learning techniques in forecasting the severity of traffic accidents. *Heliyon*, 9(8):e18812.
- Open-Meteo (2024). Open-meteo historical weather API. API pública. Disponível em: <https://open-meteo.com>. Acesso em: maio 2025.
- Polícia Rodoviária Federal (2024). Dados abertos da PRF: Sistema BAT — boletim de acidente de trânsito. Portal de Dados Abertos. Disponível em: <https://www.gov.br/prf/pt-br/aceso-a-informacao/dados-abertos/dados-abertos-da-prf>. Acesso em: maio 2025.